19 案例总结与热点问题答疑:对于左递归的语法,为什么我的推导不是左递归的?

目前为止, "编译原理"的前端部分已经讲完了, 你学到现在, 感受如何呢?

不得不说,订阅这门课程的同学,都是很有追求的。因为编译原理这门课,肯定给你的学习生涯多多少少地带来过"伤害",你现在有勇气重拾"编译原理",下决心将它攻克,本身就是一种有追求的表现。

在课程开始之初,很多同学当场立下(入)了Flag(坑),比如:

@andylo25:立下Flag,想写一个解释性语言。- @陈越:许诺会跟着学完。- @许。: 强调自己因为面试华为来学习编译原理。-

还有同学认为自己半路出家,为了长远的发展,一定要补好基本功。要我说,乔布斯还是辍学加半路出家的呢,终生学习是互联网时代的常态:

@一只豪猪: 半路出家的野路子码农来补课了。-

在准备课程的过程中,我努力把晦涩的知识点变得通俗易懂,希望得到你的认可。当我在留言 区看到一些留言时,我的内心是欣慰的,也是欣喜的:

@许童童: 之前看到词法分析什么的就是一脸蒙,看了老师的文章,醍醐灌顶。-

@VVK: 老师讲的太好了, 十几年没搞懂的概念终于整理明白了。-

与此同时,我也在不断优化课程,力求将内容做到深入浅出,比如,在策划算法篇的内容时, 我吸取一些同学的建议,尽可能画成可视化的图形,并且让整个算法的推导过程很直观地呈 现。

但是我不能回避一个事实,就是即便这些内容你认为很好,但你要想学好编译原理,还是要花费不少精力将这些内容反复地看上几遍。你需要认真跟上课程的思路和进程,用心思考和实践,才会有所得,单看内容不动手尝试是没办法学为所用的。所以,在这里,我想表扬一些有耐心,愿意尝试的同学,比如**@曾经瘦过@Unrestrained@周小明@Sam** 当然,还有很多同学在一直坚持,我为你们点赞!

而且,我发现,很多同学还有探知和质疑精神,比如,**@沉淀的梦想**发现我在示例代码里用的都是左值,也跟我讨论在实现闭包的时候,如何仍然正常访问全局变量。**@mcuking**指出 JavaScript的ES6版本已经支持块作用域 **@李梁|东大**也与我讨论了关于C++ auto变量的类型推导等等。

我知道大部分同学的时间很紧,但我感谢你们的坚持,感谢你们在努力抽时间动手实践,比如 @Smallfly 自己动手写规则; @曾经瘦过 再次动手跟着敲代码。

还有很多同学花了很多时间,用自己熟悉的语言,参照课程的示例代码重写了词法分析器、语法分析器,并分享了代码:

@ (—— ——): 写了一晚上, 终于用C语言模仿实现了第二节课的内容。-

@windpiaoxue: 也做了一个C语言实现。-

其他有Go语言的(@catplanet)、Swift语言的(@Smallfly@Rockbean@贾献华)、C++语言的(@阿尔伯特@中年男子@蛋黄儿)、TypeScript的(@缺个豆饼吗@好吃的呆梨)、PHP的(@吴军旗)等等,我通常都会编译并运行一下。

@catplanet 甚至提供了一个界面,可以通过浏览器调用自己写的编译程序,运行并显示结果。

@京京beaver 还分享了在Windows环境下如何做Antlr的配置,让其他同学可以更顺畅地运行Antlr。

@knull 建议我在写BNF的时候,用到+号Token要带上引号,避免跟原来BNF表示重复1到多次的+号冲突。

@kaixiao7 提醒我在Windows下,EOF是用Ctl+z输入。

我对你们取得的成果以及建议感到由衷的高兴和感谢,我相信,你们的分享也激励了其他同学克服困难,继续前进!

当然了,你在学习的过程中,还会遇到一些问题,我很感谢提问题的同学。其中一些问题,我 认为是比较典型,有通用意义的,**所以选了4个典型的问题,再带你详细地探究一下。**

问题一:对于左递归的语法,为什么我的推导不是左递归的?

这个问题本身反映了,进行递归下降分析的时候,如何保持清晰的思路,值得讲一讲。

在03讲,我们刚开始接触到语法分析,也刚开始接触递归下降算法。这时,我介绍了左递归的概念,但你可能在实际推导的过程中,觉得不是左递归,比如用下面这个语法,来推导"2+3"这个简单的表达式:

//简化的左递归文法 add->Int add->add + Int

你可能会拿第一个产生式做推导:

add->2- 成功返回

因为没有采用第二条产生式,所以不会触发递归调用。但这里的问题是,"2+3"是一个加法表达式,2也是一个合法的加法表达式,但仅仅解析出2是不行的,我们必须完整地解析出"2+3"来。

在17讲,我提到,任何自顶向下的算法,都是在一个大的图里找到一条搜索路径的过程。最后的结果,是经过多次推导,生成跟输入的Token串相同的结果,解析完毕以后,所有Token也耗光。



如果只匹配上2,那就证明这条搜索路径是错误的,我们必须尝试另一种可能性,也就是第二个产生式。


要找到正确的搜索路径,在递归下降算法或者LL算法时,我们都是采用"贪婪"策略,这个策略在16讲关于正则表达式时讲过。也就是要匹配尽量多的Token才可以。就算是换成右递归的文法,也不能采用第一个产生式。因为解析完Int以后,接下来的Token是+号,还可以尝试用第二个产生式,那我们就要启动贪婪策略,用第二个,而不是第一个。

//简化的右递归文法 add->Int add->Int + add

以上是第一种情况。

不过有的同学说: "我运用第二个产生式也能匹配成功,根据 'add->add + int'这个产生式,先拿第一个add去匹配2,再去匹配+号和3不就行了吗?"

这是另一种引起困扰的情况,也是我在17讲必须说一下广度优先算法的一个原因。因为这位同学的推导过程,是典型的广度优先。add非终结符,先广度优先地拆成两条路径:第一条路径匹配不成功;第二条路径进一步进行广度优先的探索,于是成功解析:



但我们在17讲也说过了,广度优先算法的性能很低,在这个简单的例子中还看不出来,但如果 是稍微复杂一点儿的语法和表达式,计算量就指数级上升。

问题二: 二元表达式的结合性的实现。


@nil: 最终通过循环来消除递归带来的二元预算符的结合性问题? 能否直接在递归中消除结合性问题?

04讲的这个问题在递归下降算法中是个难点,反映了理论上的算法用于工程实践时,会遇到的 具体问题和解决方案,所以也值得探讨。

因为递归下降算法是自顶向下、最左推导的。对于AST来说,父节点总是先于子节点来生成。因此,使用下面这个消除了左递归的加法文法来尝试解析 "2+3+4+5" 这个表达式:


```
add -> Int add'
add' -> + Int add' | ε
```

得到的AST应该是这样的:



这个AST会觉得有点儿怪,毕竟它把加法操作分成了add和add'这两种操作。针对add'这样一个节点,我们可以定义为把Int子节点和add'子节点做加法,但这样就一共要做四次计算,1个add计算,3个add'计算。并且,因为是右递归,所以计算顺序是右结合的。

如果我们想改成左结合,可以尝试改变之前的约定,就是父节点先于子节点生成,把AST强行拧成这个样子:



可以看出,这样强拧的过程,已经违背了add和add'产生式的规则。

同时,用add和add'这两个节点才能表达加法运算,还是跟我们日常的习惯相违背。与之相对的,Antlr的写法,就很符合我们日常习惯。它是根据这样的额外信息,决定解析时如何生成AST的结构:

```
add : Int
     |<assoc=left> add + add
;
```

我们文稿中的示例算法,跟这个思路类似,也是不改变加法运算的含义,但会根据结合性改变 AST节点的父子结构。这种改变,等价于我们在解析加法表达式时,不是用的最左推导,而是最 右推导。

所以, 我们可以看出:

单纯的运用递归下降算法或LL算法,我们是无法支持左结合的,一定要做一些特殊的处理。而 LR算法就不需要这些特殊处理,仅仅通过文法的设计,就能支持好结合性,这可能是很多人推 崇LR算法的原因吧。

另一方面,工程上运用良好的语法解析方法,不需要是纯粹的某一种单一的算法,增加一些辅助手段会让它更有效。比如Antlr的内部实现可以自动选择预读1个或更多个Token。必要的话还会启动回溯机制。这样做的好处,是对语法编写的要求降低,更加照顾程序员的工作效率。

问题三: 二义性文法为什么也能正常解析?

@windpiaoxue:

我测试了一下,Antlr使用上面这个规则可以正确地处理悬挂else的问题, Antlr在处理这种二义性问题的时候,是依据什么来处理的?

针对07讲中关于二义性文法的问题也有普遍意义,其实原因我在07讲里已经说了。我们实现一个算法的时候,是有确定的顺序来匹配的,所以,即使是二义性文法,在某种算法下也可以正常解析,也就是生成正确的AST。

如果我们采取深度优先的自顶向下的算法,在使用这两个产生式时:

```
stmt -> if expr stmt
stmt -> if expr stmt else stmt
```

我们就像问题一中讲加法运算时提到的那样,采用"贪婪"的算法,总是试图匹配更多的 Token。所以,只要有else,它就会去匹配else,所以else总是会跟最近的if组成一对。但采用 这个文法的时候,如果不是用贪婪策略来解析,就可能会导致if和else错配。

而严格的非二义性文法要求得比较高,它要求是算法无关的,也就是无论采用哪种推导顺序, 形成的AST是一样的。 这里的关键点,在于把"文法"和"算法"这两件事区分开,文法是二 义的,用某个具体算法却不一定是二义的。

问题四: "语法"和"文法"有什么区别和联系?

@鸠摩智:请问语法和文法有什么区别和联系?

这是一个术语的问题,确实要理清楚,你也可能会有这种疑问。

文法(Grammar),是形式语言(Formal Language)的一个术语。所以也有Formal Grammar这样的说法。这里的文法是定义清晰的规则,比如,我们的词法规则、语法规则和属性规则,都是用形式文法来定义的。

我们的课程里讲解了正则文法(Regular Grammar)、上下文无关文法(Context-free Grammar)等不同的文法规则,用来描述词法和语法。

语法分析中的语法(Syntax),主要是描述词是怎么组成句子的,一个语言的语法规则,通常指的是这个Syntax。

问题是,Grammar这个词,在中文很多应用场景中也叫做语法。这是会引起混淆的地方。我们在使用的时候要小心一点儿就行了。

比如,我做了一个规则文件,里面都是一些词法规则(Lexer Grammar),我会说,这是一个词法规则文件,或者词法文法文件。这个时候,把它说成是一个语法规则文件,就有点儿含义模糊。因为这里面并没有语法规则(Syntax Grammar)。

案例总结

在前端部分,我们伴随着文稿提供了丰富的示例程序,我相信代码是程序员之间沟通的最好手段。

第一批示例程序,是lab/craft目录下的。

通过手工实现简单的词法分析和语法分析,获得第一手的感受,破除对于编译技术的神秘感。 你会感觉到,如果要实现公式计算器甚至一个简单脚本,似乎也没那么难。

第二批示例程序,是基于AntIr工具的。

使用这个工具,实现了两个目的:

- 第一,让你借鉴成熟的规则文件,高效实现词法分析和语法分析功能。
- 第二,在不必关注词法分析和语法分析的情况下,我们把更多的精力放在了语言特性设计、 语义分析和运行期机制上。针对作用域、函数、闭包、面向对象等特性都提供了示例程序, 最终实现出一门看上去挺威风的脚本语言。

第三批示例程序,则是完成了应用篇的两个题目。

一个示范了如何通过解析SQL语句,实现分布式数据库的一个简单特性。另一个演示了如何来实现一个报表系统。通过两个实际案例将技术跟应用领域做了很好的连接,启发你按照类似的思路,去解决自己领域的问题。

第四批示例程序,是在算法篇,针对编译器前端的三组核心算法提供了示例。

这些示例程序能够根据文法规则直接做词法分析和语法分析,不需要为每一组规则单独构造词法分析器和语法分析器,实际上相当于简化版本的Lex(词法分析)、Antlr(LL语法分析)和YACC(LR语法分析)。

我给你的学习设计了多次迭代、循环提升认知的路径,从简单原理、现有工具和最佳实践、领域应用、算法逻辑等多个维度,给你全面的感受。

小结

编译原理的前端技术部分,正式告一个段落。在这个过程中,我强调地是建立直觉,掌握关键知识点,以及跟实践结合,这三个方面是关键。在短短的十多节课中,我们已经覆盖了所有关键的知识点,吃透这部分课程,会对你的实际工作有所裨益。

当然,我也知道,不到两个月的时间,你肯定不可能完全把它完全吃透,**不过,你已经在自己的知识体系中种下了一颗高质量种子,它会随着时间的流逝,伴随着你在实际应用中的体会,不断成长,并结出丰硕的果实!**

如果你还有其他的问题,欢迎在留言区提问,我会逐一解答。最后,感谢你的阅读,如果这篇文章让你有所收获,也欢迎你将它分享给更多的朋友。

© 2019 - 2023 Liangliang Lee. Powered by gin and hexo-theme-book.