28 Redis Cluster数据迁移会阻塞吗?

上节课,我给你介绍了 Redis Cluster 节点处理命令的过程。现在你知道,在这个过程中, 节点会调用 **getNodeByQuery 函数**检查访问的 key 所属的节点,如果收到命令的节点并不 是 key 所属的节点,那么当前节点就会生成 CLUSTER_REDIR_MOVED 或者 CLUSTER REDIR ASK 的报错信息,并给客户端返回 MOVED 或 ASK 命令。

其实,这两个报错信息就对应了 Redis Cluster 的数据迁移。数据迁移是分布式存储集群经常会遇到的一个问题,当集群节点承担的负载压力不均衡时,或者有新节点加入或是已有节点下线时,那么,数据就需要在不同的节点间进行迁移。所以,**如何设计和实现数据迁移也是在集群开发过程中,我们需要考虑的地方**。

那么今天这节课,我就来介绍下 Redis Cluster 是如何实现数据迁移的。从源码层面掌握这部分内容,可以帮助你了解数据迁移对集群节点正常处理命令的影响,这样你就可以选择合适时机进行迁移。而且,掌握 Redis 的数据迁移实现,也能为你自己开发集群提供一个不错的参考示例。

好了,接下来,我们就先来看下和数据迁移相关的主要数据结构。这些数据结构比较重要,它们记录了数据迁移的状态信息。

记录数据迁移的数据结构

首先你要知道, Redis Cluster 是先把键值对映射到哈希槽 (slots) 中,然后通过给不同集群节点分配 slots 这样的方法,来完成数据在集群节点间的分配的。关于这部分的知识,你也可以去看看第一季的【第9讲】。

那么,在源码实现层面,Redis Cluster 的每个集群节点都对应了一个 **clusterNode 的结构体** (在cluster.h文件中)。这个结构体中包含了一个 char 类型的数组,用来记录当前节点在负责哪些 slots。

这个数组的定义如下所示,它的长度是宏定义 CLUSTER_SLOTS 除以 8,而 CLUSTER_SLOTS 宏定义的值是 16384,表示的是 Redis Cluster 的 slots 总个数。这个值除以 8 之后,就意味着数组每个元素的每一位表示 1 个 slot。如果数组元素某一位的值是 1,那么就表明当前节点负责这一位对应的 slot。

```
typedef struct clusterNode {
    ...
    unsigned char slots[CLUSTER_SLOTS/8]
    ...
}
```

但是,如果只是用 clusterNodes 中的 slots 数组,并不能记录数据迁入迁出的情况,所以,Redis Cluster 针对整个集群设计了 clusterState 结构体(在 cluster.h 文件中)。这个结构体中包含了三个 clusterNode 类型的数组和一个 rax 类型的字典树。这三个数组的大小,都是集群 slots 的总个数 16384,如下所示:

```
typedef struct clusterState {
    ...
    clusterNode *migrating_slots_to[CLUSTER_SLOTS];
    clusterNode *importing_slots_from[CLUSTER_SLOTS];
    clusterNode *slots[CLUSTER_SLOTS];
    rax *slots_to_keys;
    ...
}
```

这几个结构主要是被用来记录数据迁入迁出的情况,它们的含义如下。

- migrating_slots_to 数组:表示当前节点负责的 slot 正在迁往哪个节点。比如, migrating_slots_to[K] = node1,这就表示当前节点负责的 slot K,正在迁往 node1。
- importing_slots_from 数组:表示当前节点正在从哪个节点迁入某个 slot。比如,importing_slots_from[L] = node3,这就表示当前节点正从 node3 迁入 slot L。
- **slots 数组**: 表示 16384 个 slot 分别是由哪个节点负责的。比如, slots[M] = node2, 这就表示 slot M 是由 node2 负责的。
- slots_to_keys 字典树: 用来记录 slot 和 key 的对应关系,可以通过它快速找到 slot 上有哪些 keys。

好了,知道了用来记录数据迁入迁出情况的数据结构之后,我们就来学习数据迁移的具体过 程。

数据迁移过程的设计与实现

Redis Cluster 迁移数据的整个过程可以分成五个大步骤,分别是:

• 标记迁入、迁出节点;

- 获取迁出的 keys;
- 源节点实际迁移数据;
- 目的节点处理迁移数据;
- 标记迁移结果。

下面,我们就分别来看下这五个步骤的源码实现。

标记迁入、迁出节点

在 Redis Cluster 中迁移数据时,我们需要先使用 CLUSTER SETSLOT 命令,在待迁入数据的目的节点上标记待迁出数据的源节点,使用的命令如下所示:

```
CLUSTER SETSLOT <slot> IMPORTING <node> //<slot>表示要迁入的哈希槽, <node>表示当前
```

然后,我们需要使用 CLUSTER SETSLOT 命令,在待迁出数据的源节点上标记将要迁入数据的目的节点,使用的命令如下所示:

```
CLUSTER SETSLOT <slot> MIGRATING <node> //<slot>表示要迁出的哈希槽, <node>表示<sl
```

为了便于你理解,我来举个例子。假设 slot 3 在节点 A 上,现在我们要把 slot 3 从节点 A 上迁移到节点 B 上,那么,此时节点 A 就是待迁出数据的源节点,而节点 B 就是待迁入数据的目的节点。我们要先在节点 B 上执行如下命令,用来标记源节点。

```
CLUSTER SETSLOT slot3 IMPORTING nodeA
```

然后, 我们在节点 A 上执行如下命令, 用来标记目的节点。

```
CLUSTER SETSLOT slot3 MIGRATING nodeB
```

对于 CLUSTER 命令来说,它的处理函数是 **clusterCommand**(在cluster.c文件中)。在 这个函数中,它会根据 CLUSTER 命令携带的不同选项,执行不同的代码分支。因此,对 于刚才介绍的标记 slot 迁入、迁出的 SETSLOT 选项,它们在 clusterCommand 函数中对 应的代码分支如下所示:

```
void clusterCommand(client *c) {
...
//处理SETSLOT选项
else if (!strcasecmp(c->argv[1]->ptr,"setslot") && c->argc >= 4) {
...
```

```
//处理migrating标记
if (!strcasecmp(c->argv[3]->ptr,"migrating") && c->argc == 5) {
...
}//处理importing标记
else if (!strcasecmp(c->argv[3]->ptr,"importing") && c->argc == 5) {
...
}
```

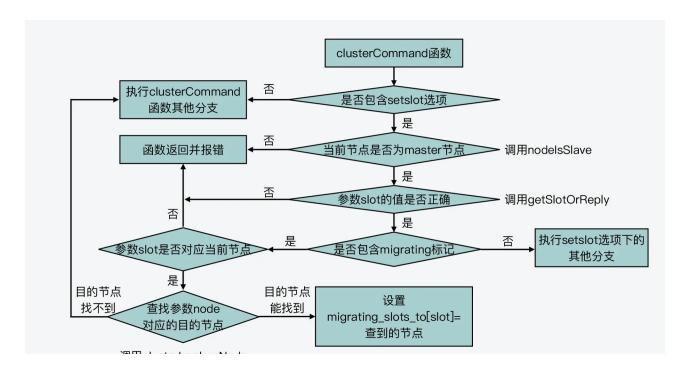
这里,我们来看一下处理 migrating 和 importing 标记的具体逻辑。其实,clusterCommand 函数对这两个标记的处理逻辑基本都是分成三步。

第一步,对于数据迁出来说,该函数会判断迁出的 slot 是否在当前节点;而对于数据迁入来说,该函数会判断迁入的 slot 是否在当前节点。如果迁出的 slot 不在当前节点,或者迁入的 slot 已在当前节点,那么 clusterCommand 函数就**返回报错信息**了。这是因为,在这两种情况下节点无法执行 slot 迁移。

第二步,如果迁出的 slot 在当前节点,或者迁入的 slot 不在当前节点,那么,clusterCommand 函数就会**调用 clusterLookupNode 函数**(在 cluster.c 文件中),来查询 CLUSTER SETSLOT 命令中包含的。这主要是依赖于 clusterLookupNode 函数根据输入的节点 ID,在全局变量 server 的 cluster->nodes 数组中,查找并返回对应节点。

第三步, clusterCommand 函数会把 migrating_slots_to 数组中迁出 slot, 或者 importing_slots_from 数组中迁入 slot 对应的节点,设置为 clusterLookupNode 函数查找的结果。

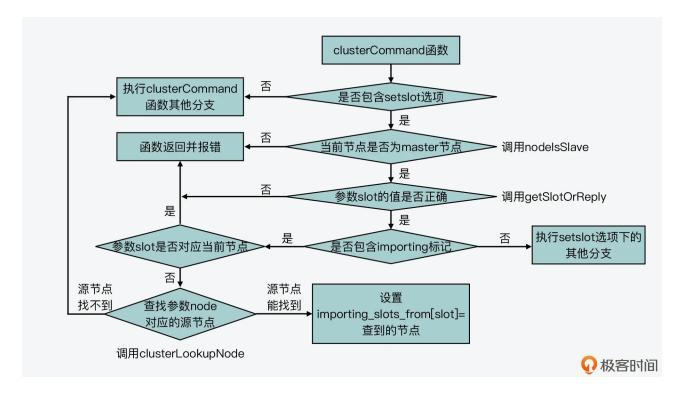
我也画了两张图,分别展示了 clusterCommand 函数处理 CLUSTER SETSLOT 命令的 migrating 和 importing 标记的基本逻辑,你可以再看下。



响用clusterLookupinoae



处理migrating标记



处理importing标记

这样一来,当在 Redis Cluster 中标记完迁入和迁出的节点后,我们就可以使用 CLUSTER GETKEYSINSLOT 命令,来获取要迁出的 keys 了。下面我们来看下这步操作的实现。

获取待迁出的 keys

我们用来获取待迁出的 keys 的具体命令如下所示,其中表示要迁移的 slot,而表示要迁移的 key 的数量。

```
CLUSTER GETKEYSINSLOT <slot> <count>
```

因为这里我们用的还是 CLUSTER 命令,所以,获取待迁出 keys 的命令处理也还是在 clusterCommand 函数中,对应了 GETKEYSINSLOT 选项的代码分支,如下所示:

```
void clusterCommand(client *c) {
...
//处理GETKEYSINSLOT选项
else if (!strcasecmp(c->argv[1]->ptr,"getkeysinslot") && c->argc == 4) {...}
...
```

这个代码分支的处理逻辑也比较简单,它主要可以分成三步。

首先,这个代码分支会**调用 getLongLongFromObjectOrReply 函数**(在object.c文件中),从 CLUSTER GETKEYSINSLOT 命令中获取和参数,这里的参数会被赋值给 maxkeys 变量,如下所示:

然后, clusterCommand 函数会调用 countKeysInSlot 函数 (在db.c文件中),获取待迁移 slot 中实际的 key 的数量。如果刚才从命令中获取的 key 的迁移数量 maxkeys,大于实际的 key 数量,那么 maxkeys 的值会被更新为实际的 key 数量。紧接着,clusterCommand 函数会给这些 key 分配空间。

```
unsigned int keys_in_slot = countKeysInSlot(slot); //获取迁移slot中实际的key数量
if (maxkeys > keys_in_slot) maxkeys = keys_in_slot; //如果实际的key数量小于maxkeys, */
keys = zmalloc(sizeof(robj*)*maxkeys); //给key分配空间
```

最后,这个代码分支会**调用 getKeysInSlot 函数**(在 db.c 文件中),从迁移 slot 中获取实际的 key,并将这些 key 返回给客户端,如下所示:

```
numkeys = getKeysInSlot(slot, keys, maxkeys); //获取实际的key addReplyMultiBulkLen(c,numkeys); //将key返回给客户端 for (j = 0; j < numkeys; j++) { addReplyBulk(c,keys[j]); decrRefCount(keys[j]); }
```

好了,到这里,客户端就通过 CLUSTER GETKEYSINSLOT 命令,获得了一定数量的要迁移的 key。接下来,我们就要开始执行实际的迁移操作了,我们来具体看下。

源节点实际迁移数据

在实际迁移数据时,我们需要在待迁出数据的源节点上**执行 MIGRATE 命令**。其实,MIGRATE 命令既支持迁移单个 key,也支持一次迁移多个 key,它们的基本处理流程是相同的,都是在 migrateCommand 函数中实现的。

这里,我以一次迁移多个 key 的 MIGRATE 命令为例,这个命令的选项中包含了目的节点

的 IP、端口号、数据库编号,以及要迁移的多个 key、迁移超时时间,它的格式如下所示:

```
MIGRATE host port "" dbid timeout [COPY | REPLACE] KEYS key1 key2 ... keyN
```

从这个命令中,你也可以看到,它还包括了 COPY 或 REPLACE 选项,这两个选项的含义如下。

- COPY: 如果目的节点已经存在待迁移的 key,则报错;如果目的节点不存在待迁移的 key,那么就正常迁移,并在迁移后,删除源节点上的 key。
- **REPLACE**: 无论目的节点是否存在待迁移的 key,都会正常执行迁移,并覆盖已经存在的 key。

好,了解了 MIGRATE 命令的含义后,我们就来看下 migrateCommand 函数的基本处理流程,这个函数的执行过程主要可以分成四步。

第一步,命令参数检查

migrateCommand 函数首先会检查 MIGRATE 命令携带的参数,比如是否有 COPY 或 REPLACE 标记、dbid 和 timeout 是否能正常读取等。在这一步,migrateCommand 函数 如果检查到 timeout 值小于等于 0 了,它就会把 timeout 值设置为 1000 毫秒,用于迁移过程中的超时判断。

第二步,读取要迁移的 key 和 value

检查完命令参数后,migrateCommand 函数会分配两个数组 ov 和 kv,它们的初始大小等于 MIGRATE 命令中要迁移的 key 的数量。然后,migrateCommand 函数会调用 lookupKeyRead 函数(在 db.c 文件中),逐一检查要迁移的 key 是否存在。这是因为有的 key 在迁移时可能正好过期了,所以就不用迁移这些 key 了。这一步的最后,migrateCommand 函数会根据实际存在的 key 数量,来设置要迁移的 key 数量。

下面的代码展示了这一步的基本逻辑,你可以看下。

num_keys = oi; //要迁移的key数量等于实际存在的key数量

第三步,填充迁移用的命令、key 和 value

接下来,migrateCommand 函数就开始为迁移数据做准备了。这一步骤中的操作主要包括:

- 调用 migrateGetSocket 函数 (在 cluster.c 文件中) ,和目的节点建立连接;
- 调用 rioInitWithBuffer 函数初始化一块缓冲区,然后调用 rioWriteBulkString、rioWriteBulkLongLong 等函数(在rio.c文件中),往这个缓冲区中填充要发送给目的节点的命令、key 和 value。

下面的代码也展示了在这一步中主要填充的命令、key 和 value, 你可以看下。

```
rioInitWithBuffer(&cmd,sdsempty()); //初始化buffer
... //往buffer中填充SELECT命令
//针对每一个要迁移的key,往buffer中填充命令、key和value
for (j = 0; j < num_keys; j++) {</pre>
   //在集群模式下,填充RESTORE-ASKING命令,用来发给目的节点
  if (server.cluster_enabled)
     serverAssertWithInfo(c,NULL, rioWriteBulkString(&cmd, "RESTORE-ASKING",14));
  serverAssertWithInfo(c,NULL,rioWriteBulkString(&cmd,kv[j]->ptr,
               sdslen(kv[j]->ptr)));
  //填充TTL
  serverAssertWithInfo(c,NULL,rioWriteBulkLongLong(&cmd,ttl));
  //调用createDumpPayload函数序列化value
  createDumpPayload(&payload,ov[j],kv[j]);
  //填充value
  serverAssertWithInfo(c,NULL, rioWriteBulkString(&cmd,payload.io.buffer.ptr,
}
```

这里,你需要注意的是,migrateCommand 函数会调用 createDumpPayload 函数(在 cluster.c 文件中)将迁移 key 的 value 序列化,以便于传输。在序列化的结果中,createDumpPayload 函数会增加 RDB 版本号和 CRC 校验和。等目的节点收到迁移数据后,也会检查这两部分内容,我稍后还会给你介绍。

当在缓冲区中填充完要发送给目的节点的命令、key 和 value 后,migrateCommand 函数就开始发送这个缓冲区中的内容了。

第四步,发送迁移用的命令和数据,并读取返回结果

migrateCommand 函数会调用 syncWrite 函数(在syncio.c文件中),把缓冲区中的内容按

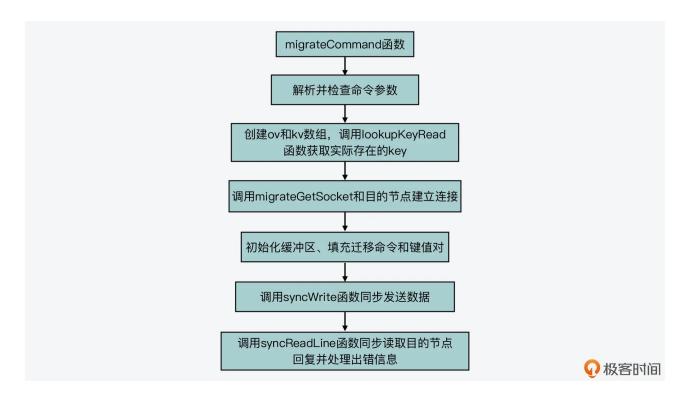
照 64KB 的粒度发送给目的节点,如下所示:

```
while ((towrite = sdslen(buf)-pos) > 0) {
   towrite = (towrite > (64*1024) ? (64*1024) : towrite);
   nwritten = syncWrite(cs->fd,buf+pos,towrite,timeout);
   ...
   pos += nwritten;
}
```

然后,针对发送给目的节点的每个键值对,migrateCommand 函数会调用 syncReadLine 函数(在 syncio.c 文件中),读取目的节点的返回结果。如果返回结果中有报错信息,那么它就会进行相应的处理。这部分的逻辑并不复杂,但是针对各种出错情况的处理会比较多,你可以进一步阅读源码来进行学习。

```
//针对迁移的每个键值对,调用syncReadLine函数读取目的节点返回结果
for (j = 0; j < num_keys; j++) {
    if (syncReadLine(cs->fd, buf2, sizeof(buf2), timeout) <= 0) { ...}
    ... //处理目的节点返回的结果
}
```

好了,到这里,你就了解了 MIGRATE 命令的执行基本过程,我把它执行过程的四大步骤也画在了下面的这张图中,你可以再回顾下。



其实在迁移数据的过程中,**目的节点对迁移命令的处理也是迁移过程的一个重要环节**。所以,下面我们就来看下,目的节点在收到 RESTORE-ASKING 命令后的处理过程。

目的节点处理迁移数据

目的节点在收到源节点发送的 RESTORE-ASKING 命令后,这个命令的实际处理函数是 **restoreCommand**(在 cluster.c 文件中)。这个函数的处理逻辑并不复杂,主要可以分成三步。

首先,它会解析收到的命令参数,包括是否覆盖数据的标记 replace、key 过期时间标记tll、key 的 LRU 标记 idletime、key 的 LFU 标记 freq。接着,它就会根据这些标记执行一系列检查。

这其中就包括,如果检测到没有 replace 标记的话,它会调用 lookupKeyWrite 函数(在db.c 文件中),检查目的节点数据库中是否有迁移的 key,如果已经存在待迁移 key 的话,它就会返回报错信息,如下所示。此外,它还会检查 TTL 值是否小于 0。

```
//如果没有replace标记,并且数据库中存在待迁移的key
if (!replace && lookupKeyWrite(c->db,c->argv[1]) != NULL) {
    addReply(c,shared.busykeyerr); //返回报错信息
    return;
}
```

然后,restoreCommand 函数会检查迁移 key 的 value 的序列化结果,就像我刚才介绍的,migrateCommand 函数在实际迁移 value 时,会把 value 序列化后再传输。而序列化后的结果中包含了 RDB 版本和 CRC 校验和,restoreCommand 函数会调用 verifyDumpPayload 函数(在 cluster.c 文件中),检测 RDB 版本和 CRC 校验和。如果这两部分内容不正确,它就会返回报错信息。

```
//检查value序列化结果中的RDB版本和CRC校验和
if (verifyDumpPayload(c->argv[3]->ptr,sdslen(c->argv[3]->ptr)) == C_ERR)
{
    addReplyError(c,"DUMP payload version or checksum are wrong");
    return;
}
```

紧接着,restoreCommand 函数会调用 rdbLoadObjectType 函数和 rdbLoadObject 函数 (在rdb.c文件中),从序列化结果中解析出实际的 value 类型和 value 实际值。

最后,restoreCommand 函数会调用 dbAdd 函数,把解析得到 key 和 value 写入目的节点的数据库中。这里,你要注意的是,如果迁移命令中带有 REPLACE 标记,那么,restoreCommand 函数会先调用 dbDelete 函数,删除在目的节点数据库中已经存在的迁移 key,然后再调用 dbAdd 函数写入迁移 key。此外,restoreCommand 函数还会设置迁移 key 的过期时间,以及 LRU 或 LFU 信息,并最终返回成功信息。

下面的代码展示了 restoreCommand 函数最后一步的处理逻辑,你可以看下。

```
//如果有REPLACE标记,在目的节点数据库中删除已存在的迁移key if (replace) dbDelete(c->db,c->argv[1]);

//将迁移key及value写入目的节点数据库 dbAdd(c->db,c->argv[1],obj);
if (ttl) { //设置TTL时间
        if (!absttl) ttl+=mstime();
        setExpire(c,c->db,c->argv[1],ttl);
}
objectSetLRUOrLFU(obj,lfu_freq,lru_idle,lru_clock); //设置LRU或LFU信息 ...
addReply(c,shared.ok); //返回成功信息
```

我在这里也画了一张图,展示了目的节点处理迁移数据的基本过程,你可以再整体看下。



好了,到这里,你就了解了源节点发送迁移数据,以及目的节点接收迁移数据的基本过程实现了。最后,当迁移 slot 中的 key 全部完成迁移后,我们还需要执行 CLUSTER SETSLOT 命令,来标记迁移的最终结果,下面我们来看下。

标记迁移结果

在数据迁移完成后,我们需要先在目的节点上**执行 CLUSTER SETSLOT 命令**,向目的节点标记迁移 slot 的最终所属节点,如下所示。然后,我们需要在源节点上执行相同的命令,用来向源节点标记迁移 slot 的最终所属节点。

CLUSTER SETSLOT <slot> NODE <node>

因为这个命令还是 CLUSTER 命令,所以它的处理仍然在 **clusterCommand 函数**中实现的。这个命令的选项是 SETSLOT,并带有 NODE 标记,所以它对应的代码分支如下所示:

```
void clusterCommand(client *c) {
    ...
    //处理SETSLOT选项
    else if (!strcasecmp(c->argv[1]->ptr,"setslot") && c->argc >= 4) {
        ...
        //处理NODE标记
        else if (!strcasecmp(c->argv[3]->ptr,"node") && c->argc == 5) { ...}
        ...
    }
    ...
}
```

在刚才介绍的处理 NODE 标记的代码分支中,主要的工作是清除节点上 migrating_slots_to数组和 importing_slots_from 数组中的标记。

对于 migrating_slots_to 数组来说,在源节点上,这个数组中迁移 slot 所对应的元素,记录了目的节点。那么,在源节点上执行迁移结果标记命令时,处理 NODE 标记的代码分支,就会调用 countKeysInSlot 函数(在 db.c 文件中)检查迁移 slot 中是否还有 key。如果没有 key 了,那么 migrating_slots_to 数组中迁移 slot 所对应的元素会被置为 NULL,也就是取消了源节点上的迁出标记。

```
if (countKeysInSlot(slot) == 0 && server.cluster->migrating_slots_to[slot]) //如果有
    server.cluster->migrating_slots_to[slot] = NULL; //将迁出标记置为NULL
```

而对于 importing_slots_from 数组来说,在目的节点上,这个数组中迁移 slot 所对应的元素记录了源节点。那么,在目的节点上执行迁移结果标记命令时,处理 NODE 标记的代码分支会**检查命令参数中的****是否就是目的节点自身**。如果是的话,importing_slots_from数组中迁移 slot 所对应的元素会被置为 NULL,这就是取消了目的节点上的迁入标记。

```
//如果命令参数中的节点是当前节点,并且有迁入标记
if (n == myself && server.cluster->importing_slots_from[slot]) {
    ...
    server.cluster->importing_slots_from[slot] = NULL; //取消迁入标记
}
```

最后,处理 NODE 标记的代码分支,会调用 clusterDelSlot 和 clusterAddSlot 函数(在 cluster.c 文件中),分别更新 slot 迁移前和迁移后所属节点的 slots 数组,你可以去进一步阅读这两个函数的代码进行了解。

到这里,Redis Cluster 中数据迁移的整个过程也就完成了。

小结

在今天的课程中,我给你介绍了 Redis Cluster 数据迁移过程的代码实现,你要掌握以下两个要点。

首先是记录集群状态的数据结构 clusterState。这个结构中是使用了 migrating_slots_to 和 importing_slots_from 两个数组,来记录数据迁出迁入情况,使用了 slots 数组记录每个 slot 所属的节点,以及使用 slots_to_keys 字典树记录 slots 中的 keys。你需要掌握这几个数据结构的含义,因为在你阅读集群源码时,这几个结构是会频繁使用到的。

然后是数据迁移过程的五大步骤。分别是:

- 标记迁入、迁出节点;
- 获取待迁出的 keys;
- 源节点实际迁移数据;
- 目的节点处理迁移数据;
- 标记迁移结果。

这五个步骤对应了 CLUSTER 命令的不同选项、MIGRATE 命令以及 RESTORE 命令,所以,它们的实现逻辑就主要对应在 clusterCommand、migrateCommand 和 restoreCommand 函数中。如果你想了解数据迁移的更多细节,你可以从这几个函数入手进一步学习。

最后,我也想再**提醒你两个关键点**。

一是,Redis Cluster 在执行数据迁移时,会调用 syncWrite 和 syncReadLine 函数,向目的节点同步发送迁移数据,以及同步读取回复结果。而这个同步写和同步读的过程,会阻塞源节点正常处理请求。所以,你在迁移数据时要**控制迁移的 key 数量和 key 大小**,避免一次性迁移过多的 key 或是过大的 key,而导致 Redis 阻塞。

二是,我们在实际应用中,会用到 **redis-cli 工具**,或者是 Ruby 开发的 Redis Cluster 集群 **运维工具 redis-trib**,来执行数据迁移。这些工具最终也会调用这节课中,我们介绍的命令 来完成数据的实际迁移。所以,学习今天课程的内容,对于你在实际应用中,从代码层面排查 redis-cli、redis-trib 这些工具的问题也是有所帮助的。

每课一问

在维护 Redis Cluster 集群状态的数据结构 clusterState 中,有一个字典树 slots_to_keys。

当在数据库中插入 key 时它会被更新,你能在 Redis 源码文件 db.c 中,找到更新 slots_to_keys 字典树的相关函数调用吗?